

논문 심사 답변서

◇ 논문 번호 : 202302-033-B-RN

◇ 논문 제목 : TDoA 확률화 이미지를 활용한 딥러닝 기반 타겟 추적 모델

◇ 유의 사항

1. '2차 수정 논문' 과 '2차 답변서' 로 파일명을 작성한다.
2. 심사의견이 반영된 사항은 붉은색 또는 파란색으로 표시한다.
3. 답변서는 별도의 문서로 작성하여 수정본과 함께 제출한다.
4. 수정투고 기한은 결과 통보일로부터 15 ~ 25일이나 기한 내 제출이 어려울 경우 연장할 수 있다.

(단, 저자는 위 사항을 학회 논문 담당자에게 통보해야 하며 통보 시 제출 가능한 일자를 지정해야 한다.)

※ 심사의견 및 답변사항

[심사 의견 1] 심사의견을 충분히 반영하여 수정, 보완이 이루어진 후 재심사가 필요합니다.

[답변 사항 1]

논문의 내용을 향상시킬 수 있는 소중한 의견을 주셔서 감사드립니다. 의견들을 바탕으로 수정하여 원고가 보다 명확해지고 논문의 가치가 높아졌다고 생각이 듭니다. 저자들은 주로 아래의 항목에 유의하여 원고를 수정하였습니다.

- 딥러닝을 활용한 TDoA 기반 측위 방법 사전 연구 파트 강화 및 DB 구축을 해결할 수 있는 추후 연구 방법 제안
- 정확한 한글 용어 사용 및 비문 개선

해당 원고를 수정하여 학회지 게재를 다시 고려 받을 수 있는 기회를 주셔서 감사드립니다.

[심사 의견 2-1] 제안한 방법은 TDoA 기반의 측위 방법의 성능 향상을 위해 TDoA 이미지 DB를 구축하고 이에 대한 deep learning 기법을 적용한 경우이다. 확정된 환경에서는 제안된 방법을 통해 일반적인 TDoA 기반 측위 방법에 비해 우월한 결과를 얻을 수 있겠지만 환경(측위가 이루어져야 하는 장소)을 바꿔서 제안된 방법을 적용하려면 해당 TDoA 이미지 DB 구축이 전제되어야 한다. 이는 제안된 방법이 TDoA 기반 측위 방법에 대한 개선책으로 간주될 수 없는 이유이다.

[답변 사항 2-1]

답변 감사드립니다. 지적해주신대로, 딥러닝을 활용한 측위 방법은 다량의 학습 데이터가 필수적입니다. 이를 보완하기 위해 추후로 진행되어야 할 부분에 대해 내용을 추가하였습니다.

- 2.1.1 2번째 문단

이러한 문제점을 해결하고자 현재 딥러닝을 활용한 측위 시스템이 연구되고 있다. 딥러닝은 컴퓨터 시뮬레이션 또는 실제 데이터 수집을 통해 얻은 대량의 학습 데이터를 활용하여 복잡한 패턴과 관계를 자동으로 인식하는 인공지능 알고리즘의 한 분야이다. 딥러닝 기반 TDoA 측위 기술은[9-13] 높은 측위 정확성, AWGN 패턴 학습에 따른 강건성, 그리고 수동적 특성 설계 없이 자동으로 유용한 특성을 학습하는 능력을 가지고 있어 현재 많은 연구가 진행되고 있는 분야이다.

노이즈에 강인한 딥러닝 모델을 학습하는 방법에는 신호의 연속성을 활용한 시계열 기반의 방법이 존재한다.

- 4.결론 2번째 문단

본 연구는 딥러닝 모델을 기반으로 하고 있으므로, 다음의 한계점을 가지고 있다. 학습에 사용될 수 있는 TDoA 데이터베이스가 존재하지 않거나 그 양이 매우 적은 경우 높은 성능을 얻기 어렵다. 추후 연구로서, 다른 대량의 데이터로 이미 학습된 모델을 활용하는 방식인 전이 학습(Transfer Learning)이나, 다른 환경에서 학습된 모델을 새로운 환경에 맞게 조정하는 도메인 적응 기법(Domain Adaptation)을 도입해보고자 한다. 이를 통해 TDoA 데이터베이스 구축 과정을 간소화한다면 제안 방법의 활용성이 증대될 것이다.

[심사 의견 2-2] 한글 논문인데 부적절한 영어 사용이 많고 오타자도 다수 존재한다

[답변 사항 2-2]

답변 감사드립니다. 지적하신 영어 사용 부분 및 오타자 부분들에 대해서 수정을 진행하였습니다.

- 국문으로 수정을 진행한 영어 사용 부분 예시

Multipath→다중 경로, end-to-end→종단간 방식, masking→마스킹, PHY layer→물리 계층, deep learning→딥러닝, hyper parameter →하이퍼파라미터, stochastic& deterministic→확률적&결정론적 등

[심사 의견 3-1] 아래와 같이 오류를 수정하여 주세요. 1) (오류 문장) 신경망 모델을 사용하여 이동하는 태그의 위치 좌표를 추적 과 같다. 2) 식 (3)을 (1)로 수정 3) Table2-3로 => Table 2와 3으로

[답변 사항 3-1]

답변 감사드립니다. 지적하신 오타자 부분들에 대해서 수정을 진행하였습니다.

- 2.2.1 1번째 문단

모델의 프로세스는 다음과 같다: 1) 관측한 TDoA는 격자 지역에 태그가 존재할 확률로 구성된 이미지로 변환하는 과정을 거친다. 이렇게 변환한 이미지들은 합쳐져 특정 시간 t 에 각각의 앵커에서 관측한 TDoA 3D Tensor로 합쳐진다. 2) TDoA 3D Tensor는 시계열 데이터로 전환하기 위해 고정된 창(windows)을 이용해 4차원 구조의 데이터(TDoA 4D Tensor)로 전환한다. 3) 타겟의 위치 정보가 적혀 있는 이미지 데이터(TDoA 4D Tensor)를 Convolutional-LSTM 신경망 모델을 사용하여 이동하는 태그의 위치 좌표를 추적한다.

- 2.2.2 2번째 문단

$$C_{i,j} = A + [(0.5 + i) \times \text{Grid size}, (0.5 + j) \times \text{Grid size}] \quad (1)$$

- 3.3 첫번째 문단

실험 결과는 Table 2와 3에 나타나 있다.

[심사 의견 3-2] 전체적으로 문장 수정이 필요로 합니다.

[답변 사항 3-2]

답변 감사드립니다. 지적하신 부분들에 대해서 글 전반적으로 수정을 진행하였습니다.

- 1.서론 2번째 문단

그 중 UWB는 500MHz 이상의 넓은 주파수 대역을 사용하여 짧은 시간 동안 낮은 출력의 펄스 신호로 100m 이내에서 데이터를 송수신하는 무선통신 기술이다^[3]. UWB는 높은 측위 정확성, 다중 경로 간섭에 대한 저항성, 측정값에 대한 안정성, 물리 계층(PHY layer)에서 난수를 활용한 보안성과 같은 장점을 가진다.

- 1.서론 3번째 문단

문제를 보완하기 위해 서로 다른 앵커(수신기)에서 측정된 신호 시간의 차이를 이용하는 TDoA (Time Difference of Arrival) 방식이 주로 사용된다. TDoA를 활용한 위치 추적 방식에서 태그는 앵커와 개별적인 통신을 하지 않고 블링크 메시지(Blink Message)만을 전송함으로써 배터리 소모를 절감할 수 있다. 또한, 주소 바인딩이 없고 한 번의 전송으로 많은 태그에 신호를 보낼 수 있어, 동시에 다수의 태그와 통신이 가능하다.

- 1.서론 3번째 문단

해당 방법들로 인해 TDoA 기반 위치 추정 속도는 개선되었지만, 입력 값의 오차에 민감하게 반응하기 때문에[15], 장애물이 많은 공간에서는 사용하기 어려운 방법이다.

신호 오류에 강건한 물체 추적 모델을 구축하기 위해, 머신러닝 및 딥러닝 기법을 활용한 방법들이 연구되고 있다[8-13].

- 1.서론 5번째 문단

제안된 방법은 이미지 변환 과정을 통해 AWGN이 측위에 미치는 영향을 감소시킨다. 게다가, 측정된 TDoA를 그대로 사용하는 종단간(End-to-End) 방식이기에 프로세스가 간단하므로 실시간 위치 측정에 적합하다. 마지막으로, 연속적으로 움직이는 타겟의 특성을 고려해 시계열 모델을 도입함으로써 성능을 크게 향상시켰다.

- 2.1.1 6,7번째 문단

실험 결과, TITT는 높은 AWGN의 상황에서 다른 모델에 비해 강건한 위치 추정 결과를 보였다.

그러나 TITT는 AWGN이 많이 발생하는 극단적인 환경에서만 실험된 한정적인 결과를 보여 한계가 있다. 또한, TDoA 기반 방법에서는 신호의 연속성을 고려한 접근이[9-11] 좋은 성능을 보이지만, TITT는 시계열 특성을 고려하지 않았다. 이에 더해, TDoA 이미지 픽셀들은 TDoA 쌍곡선 방정식의 추정 결과이지만, TITT를 통해 구한 추정 값이 확률적(stochastic)이 아닌 결정론적(deterministic)으로 표현되고 있다. 불확실성 고려하지 않는 TITT의 결정론적 방식은 훈련 데이터에 대한 과적합 위험과 강건한 모델 학습의 어려움에 대한 한계를^[9] 지니고 있다.

- 2.1.2 1번째 문단

이미지 데이터를 LSTM 모델에 사용하기 위해선 이미지를 벡터로 변환해야 하는데, 이 과정에서 이미지의 지역적 정보(topological information)가 손실되어 학습 시간과 성능이 크게 저하된

다.

- 2.1.2 2번째 문단

두 가지 차이점 덕분에 시간적, 공간적 상관성(Spatiotemporal correlation)을 동시에 학습할 수 있다는 큰 장점이 있다

- 2.2.4 1번째 문단

TPITT는 실시간으로 이동 중인 물체의 위치 추정을 위해 Convolutional-LSTM 모델을 활용한다.

- 3.1 3번째 문단

각 환경에서 물체의 움직임에 따른 TDoA 데이터를 생성하였다.

- 3.3 1번째 문단

분산 또한 Table 3에서 확인할 수 있는데, Noise Extreme & Random Whole 상황을 제외한 모든 상황에서 Convolutional-LSTM이 다른 모델에 비해 좋은 결과를 보였으며, 최대 0.05만큼 낮은 분산 값을 보였다. Convolutional-LSTM 모델은 시계열 정보를 활용함으로써 물체가 학습 시와 다른 움직임을 보이는 경우에도 위치를 잘 파악할 수 있었다.

- 4.결론

본 연구는 이미지 변환 과정을 통해 AWGN을 감소시키고, 다양한 타겟과 환경에서 일반적으로 사용할 수 있는 위치 추적 방법인 TPITT 모델을 제안하였다. 실험 결과 TDOA 이미지 기반의 TPITT 모델은 FCNNs 모델과 비교했을 때, 일반적이지 않은 다양한 상황에서 안정된 성능을 보였다. 또한, AWGN이 많은 환경에서 TITT보다 더 낮은 예측 오류를 보였다. 이는 TPITT의 확률화 과정이 AWGN에 대한 강건성을 향상시킬 수 있음을 의미한다. 마지막으로, 다른 모델들과 비교하여 Convolutional-LSTM 모델이 전반적으로 가장 우수한 성능을 보였다. UWB 신호의 시계열 정보를 활용하는 것이 효과적임을 알 수 있었다.

본 연구는 딥러닝 모델을 기반으로 하고 있으므로, 다음의 한계점을 가지고 있다. 학습에 사용될 수 있는 TDoA 데이터베이스가 존재하지 않거나 그 양이 매우 적은 경우 높은 성능을 얻기 어렵다. 추후 연구로서, 다른 대량의 데이터로 이미 학습된 모델을 활용하는 방식인 전이 학습(Transfer Learning)이나, 다른 환경에서 학습된 모델을 새로운 환경에 맞게 조정하는 도메인 적응 기법(Domain Adaptation)을 도입해보고자 한다. 이를 통해 TDoA 데이터베이스 구축 과정을 줄인다면 다양한 상황에서 보편적으로 사용할 수 있을 것이다.