


AnoGAN & GANomaly

AnoGAN

■ Introduction

- 이상 탐지(Anomaly)는 데이터에서 비정상적인 값을 탐지하는 것
- Anomaly Detection Supervised learning을 학습하기 위해선 이상 데이터가 많이 필요
 - 하지만 실제론 이상치 데이터를 거의 구할 수 없음
- 이러한 단점을 해결하기 위해 GAN을 많이 사용
 - normal한 데이터만을 학습해서 abnormal한 데이터를 식별할 수 있음




(a) Normal Data (X-ray Scans)

(b) Normal + Abnormal Data (X-ray Scans)

AnoGAN

■ Model Structure

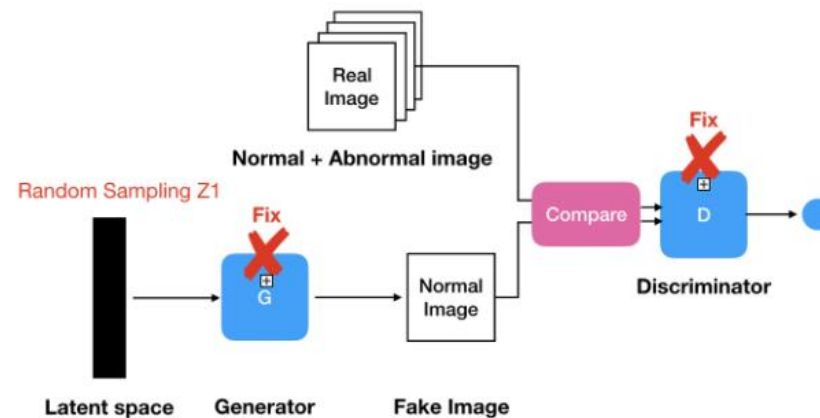
- AnoGAN[2017, International conference on information processing in medical imaging]은 다음과 같이 여러 단계를 거침
 1. G는 normal한 데이터만 생성하며 이를 위해 **normal data만 사용하여 학습** 진행



AnoGAN

■ Model Structure

- AnoGAN은 다음과 같이 여러 단계를 거침
 1. G는 normal한 데이터만 생성하며 이를 위해 **normal data만 사용하여 학습** 진행
 2. G의 학습이 잘 진행되었다면, G와 D를 freeze 하고 랜덤 샘플링을 진행하면서 **normal image를 가장 잘 생성하는 latent vector** 찾음



AnoGAN

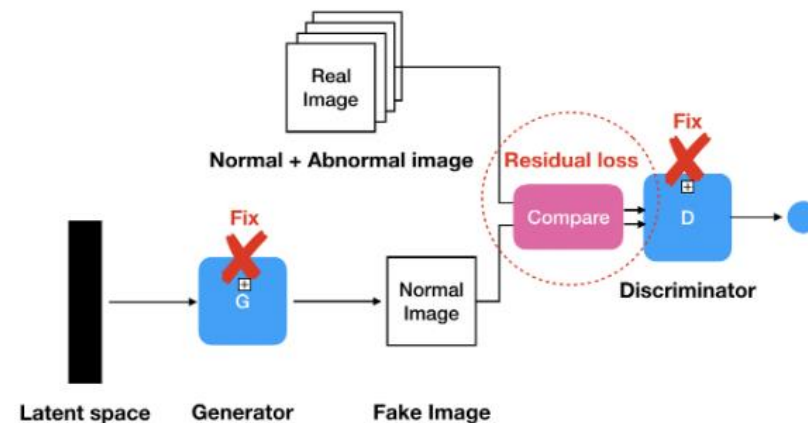
Model Structure

- AnoGAN은 다음과 같이 여러 단계를 거침
 - G는 normal한 데이터만 생성하며 이를 위해 **normal data만 사용하여 학습** 진행
 - G의 학습이 잘 진행되었다면, G와 D를 freeze 하고 랜덤 샘플링을 진행하면서 **normal image를 가장 잘 생성하는 latent vector** 찾음
 - Real image(정상 + 비정상)과 생성한 정상 이미지와 다른 부분을 비교**하며 residual loss를 이용해 학습

$$\mathcal{L}_R(\mathbf{z}_\gamma) = \sum |\mathbf{x} - G(\mathbf{z}_\gamma)|.$$

Residual Loss

Normal real sample의 Mainfold X -- 완벽하게 normal 데이터를 생성하는 $G(\mathbf{z})$



AnoGAN


Model Structure

- AnoGAN은 다음과 같이 여러 단계를 거침
 - G는 normal한 데이터만 생성하며 이를 위해 **normal data만 사용하여 학습** 진행
 - G의 학습이 잘 진행되었다면, G와 D를 freeze 하고 랜덤 샘플링을 진행하면서 **normal image를 가장 잘 생성하는 latent vector** 찾음
 - Real image(정상 + 비정상)과 생성한 정상 이미지와 다른 부분을 비교**하며 residual loss를 이용해 학습
 - 2에서 찾은 latent vector로 만든 **가짜 이미지들이 동일한 분포에 mapping 되는지** discrimination loss를 이용해 학습

$$\mathcal{L}_D(\mathbf{z}_\gamma) = \sum |\mathbf{f}(\mathbf{x}) - \mathbf{f}(G(\mathbf{z}_\gamma))|$$

Discrimination Loss

Discrimination loss는 \mathbf{z} 값에 의 해 만들어 내는 이미지 $G(\mathbf{z}_r)$ 이 Distribution에 잘 mapping 되는가에 대한 패널티 부여




AnoGAN

Model Structure

- AnoGAN은 다음과 같이 여러 단계를 거침
 - G는 normal한 데이터만 생성하며 이를 위해 **normal data만 사용하여 학습** 진행
 - G의 학습이 잘 진행되었다면, G와 D를 freeze 하고 랜덤 샘플링을 진행하면서 **normal image를 가장 잘 생성하는 latent vector** 찾음
 - Real image(정상 + 비정상)과 생성한 정상 이미지와 다른 부분을 비교**하며 residual loss를 이용해 학습
 - 2에서 찾은 latent vector로 만든 **가짜 이미지들이 동일한 분포에 mapping 되는지** discrimination loss를 이용해 학습
 - 3-4번을 반복하며 경쟁적으로 모델을 최종적으로 학습

- 학습이 완료된 후 normal한 실제 이미지가 들어오면 total loss는 작고, abnormal한 이미지의 total loss는 크다

$$\mathcal{L}(\mathbf{z}_\gamma) = (1 - \lambda) \cdot \mathcal{L}_R(\mathbf{z}_\gamma) + \lambda \cdot \mathcal{L}_D(\mathbf{z}_\gamma)$$



GANomaly

■ Introduction

- 앞선 AnoGAN은 여러 단계를 거침
- 이러한 복잡한 프로세스 대신 이미지 생성 과정과 latent space를 학습하는 과정을 한꺼번에 진행하는 모델 제안
- GANomaly는 18년도 Asian conference on computer vision 에서 처음 발표
- 해당 모델은 AnoGAN과 BiGAN(Bidirectional GAN에다가 encoder를 포함하여 연장)을 접목
- normal sample에서 generator가 manifold x 를 학습하도록 하는 동시에 autoencoder가 image를 latent representation으로 얼마나 효과적으로 encodeing하는지를 학습함




Figure 1. The structure of BiGAN proposed in (Donahue et al., 2016).

GANomaly

■ Model Structure

- Generator : encoder-decoder-encoder 구조를 사용함으로써 모델이 인풋 이미지를 저차원의 벡터로 잘 매핑
- G encoder(앞-뒤에 있는 encoder는 동일한 구조)
 - ① Input은 image X 이며 X 가 인코더를 통해 feature vector Z 로 변경
 - ② Z 를 디코더를 통해 다시 이미지로 복원(\hat{X})
 - ③ 복원된 이미지(\hat{X})을 다시 인코더를 거쳐 \hat{Z} 으로 변경
- 구조 이점
 - Autoencoder 구조에 기초한 anomaly detection을 수행
 - Generator 끝의 encoder E 는 encoder가 이미지를 잘 학습할 수 있도록 도와줌(x 의 가장 좋은 representation이 \hat{X} 을 재구성 하기 때문)

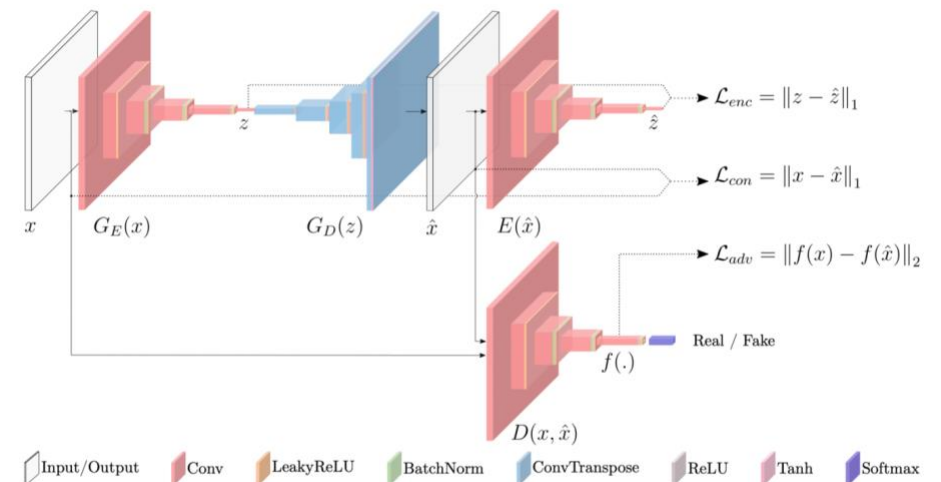
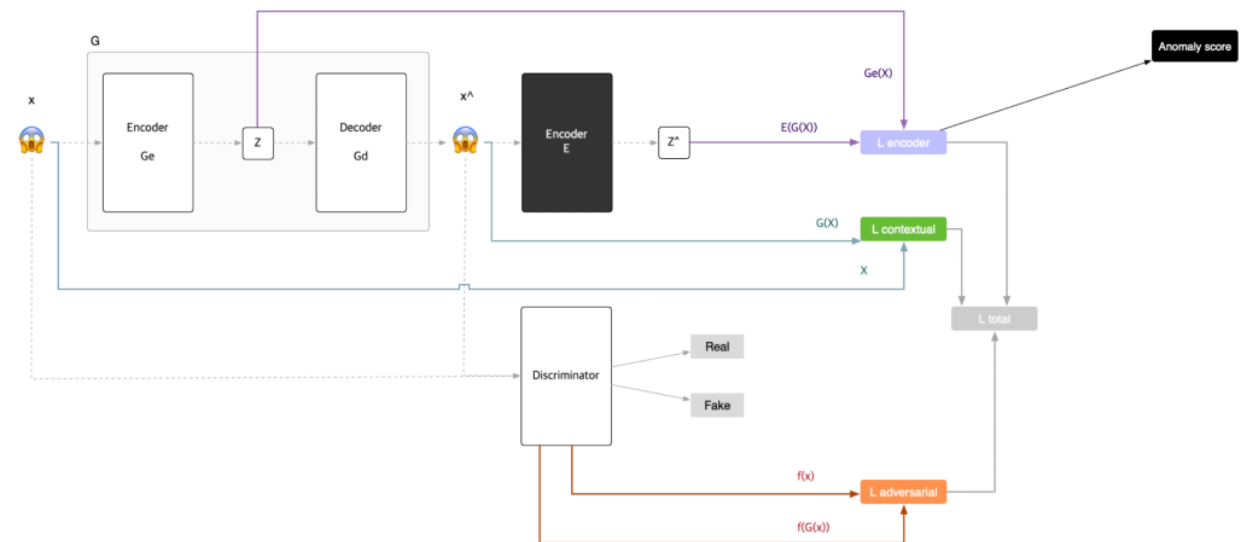


Figure 3. GANomaly architecture and loss functions from (Akçay et al., 2018).

GANomaly

■ Model Structure

- Discriminator : standard GAN 구조(일반적인 adversarial training에서 실제와 만들어진 이미지를 구분하도록 학습)
- 세가지 다른 loss를 합쳐서 generator loss로 사용



GANomaly

■ Generator Loss Function

- Adversarial loss, Contextual loss, Encoder loss를 합쳐서 사용 $\mathcal{L} = w_{adv}\mathcal{L}_{adv} + w_{con}\mathcal{L}_{con} + w_{enc}\mathcal{L}_{enc}$
- Adversarial loss : feature matching loss (discriminator의 layer다 인풋의 특징 representation을 뽑기 위해 사용)
$$\mathcal{L}_{adv} = \mathbb{E}_{\mathbf{x} \sim p_X} \|f(\mathbf{x}) - \mathbb{E}_{\mathbf{x} \sim p_X} f(G(\mathbf{x}))\|_2,$$
- Contextual loss : input data의 contextual information을 학습
$$\mathcal{L}_{con} = \mathbb{E}_{\mathbf{x} \sim p_X} \|x - G(\mathbf{x})\|_1.$$
- Encoder loss : normal image를 어떻게 잘 encoding하는지를 학습
$$\mathcal{L}_{enc} = \mathbb{E}_{\mathbf{x} \sim p_X} \|G_E(\mathbf{x}) - E(G(\mathbf{x}))\|_2.$$

GANomaly

- **Anomaly score**

- Test 단계에서 저자는 anomaly score를 계산하기 위해 새로운 식 도입

- 모든 sample \hat{x} 에 대해 매번 anomaly score 계산 수행

$$\mathcal{A}(\mathbf{x}) = \|G_E(\mathbf{x}) - E(G(\mathbf{x}))\|_2 . \quad (12)$$

$$\mathcal{S} = \left\{ s_i : \mathcal{A}(\hat{x}_i), \hat{x}_i \in \hat{D} \right\}$$

- D는 데이터셋 / A는 샘플 x의 encoder loss

$$s'_i = \frac{s_i + \min(S)}{\max(S) - \min(S)} . \quad (13)$$

- 즉, 전체 데이터의 anomaly 값들을 feature scale한 뒤, 이를 평가하는 방식

GANomaly

Experiments

- AnoGAN은 iteration 과 같은 작업때문에 테스트를 수행하기가 어려워서 비교하지 않음
- 원래 논문을 완전히 그대로 구현하진 않고 각각 모델에서 최대한 최적화를 한 수정된 버전들을 사용
- MNIST와 Fashion-MNIST 데이터로 테스트 시에 BiGAN기반이 월등히 잘 나옴

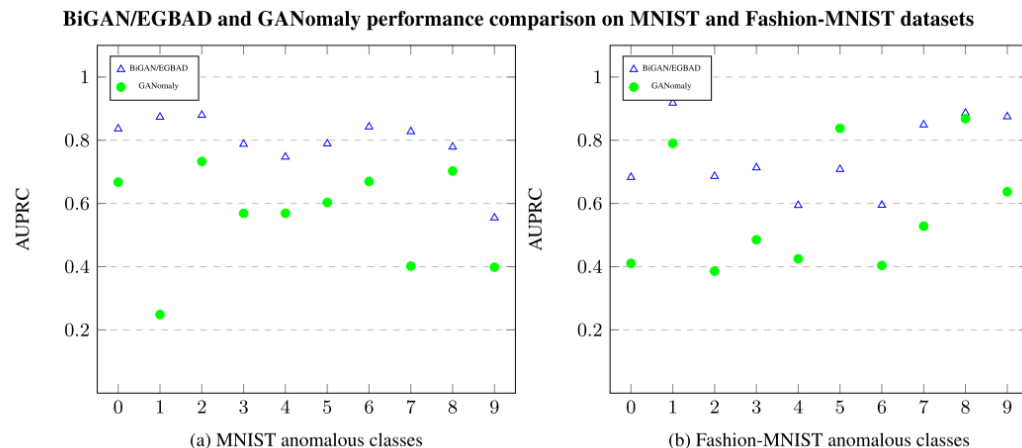


Figure 5. Performance on MNIST (a) and Fashion-MNIST (b) of BiGAN/EGBAD and GANomaly models measured by the area under the precision-recall curve (AUPRC). The results have been selected as the best result between different type of training (with bce/fm and with residual loss). Best viewed in color.

	Train			Test	
	BCE	FM	Residual	BCE	FM
Case 1	✓		✓	✓	✓
Case 2		✓	✓	✓	✓
Case 3	✓			✓	✓
Case 4		✓		✓	✓

Table 1. BiGAN - Training and testing configuration combinations.

	KDD		
	Precision	Recall	F1-Score
BiGAN/EGBAD	0.941174	0.956155	0.948605
GANomaly	0.830256	0.841112	0.835648

Table 3. The performances of BiGAN/EGBAD and GANomaly models on the KDD dataset.

GANomaly

■ Conclusion

- AnoGAN처럼 research process가 필요하진 않음 (encoder로 인해서 iteration 값을 찾을 필요가 없음)
- autoencoder와 유사한 구조를 사용함으로써 학습이 더 빠름
- image space와 latent space에서 모두 anomaly를 검출하지만 두개의 결과가 일치하지는 않을 수 있음
- 뒷 부분 Encoder 방식이 필요한지 의문이 듦
 - 생성된 이미지를 굳이 압축시키지 말고 feature distance 등 방법을 사용했다면 오히려 모델이 더 간단 해지지 않았을까?
 - 디코더로 압축하는 과정에서 공간성 등 여러 정보들이 손실될 수 있는데 이러한 비교가 맞는 비교인지 의문이 듦
 - 또한 인풋이 거의 비슷할텐데 image space와 latent space의 결과가 그렇게 차이가 날까 하는 생각이 듦